## Московский государственный технический университет им. Н. Э. Баумана Факультет «Информатика и системы управления»

Кафедра «Системы обработки информации и управления» Курс «Технологии машинного обучения»

> Отчет по лабораторной работе №6 Ансамбли моделей машинного обучения

Группа: РТ5-61

Студент: Коржов С.Ю.

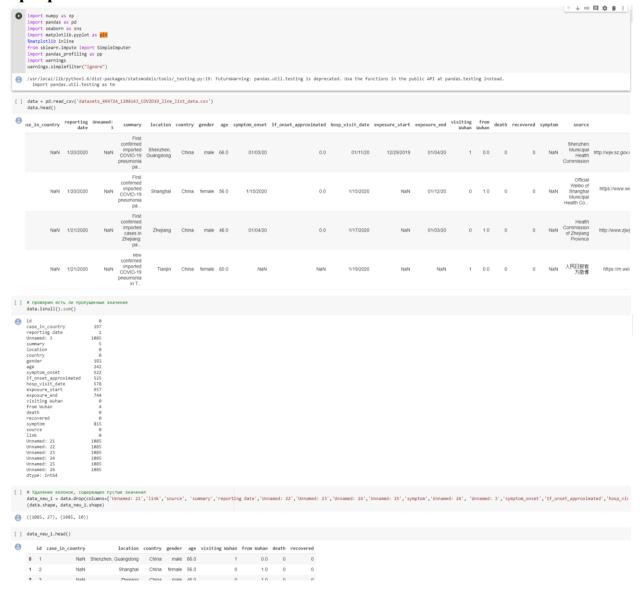
Преподаватель: Гапанюк Ю.Е.

**Цель лабораторной работы:** изучение ансамблей моделей машинного обучения.

## Задание:

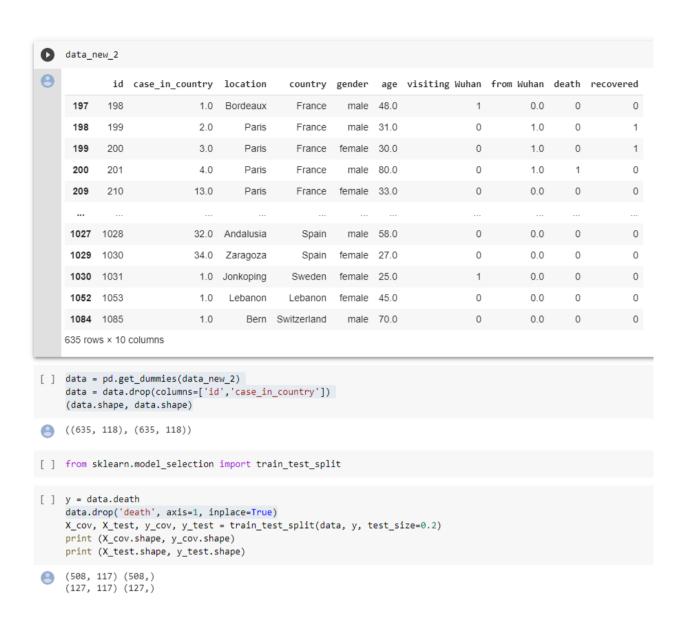
- 1. Выберите набор данных (датасет) для решения задачи классификации или регресии.
- 2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
- 3. С использованием метода train\_test\_split разделите выборку на обучающую и тестовую.
- 4. Обучите две ансамблевые модели. Оцените качество моделей с помощью одной из подходящих для задачи метрик. Сравните качество полученных моделей.

## Текст программы и экранные формы с примерами выполнения программы:



```
[ ] data_new_1.isnull().sum()
e id
    case_in_country
                       197
    location
                       0
    country
                        0
    gender
                       183
    age
                       242
    visiting Wuhan
                        Θ
    from Wuhan
                        4
    death
                         0
    recovered
                         0
    dtype: int64
[ ] # Удаление строки, содержащих пустые значения
    data_new_2 = data_new_1.dropna(axis=0,how='any',subset=['case_in_country','gender', 'age'])
    (data_new_1.shape, data_new_2.shape)
((1085, 10), (635, 10))
[ ] data_new_2.head()
8
           id case_in_country location country gender age visiting Wuhan from Wuhan
                                                                                             death recovered
     197 198
                           1.0 Bordeaux
                                                    male 48.0
                                                                                     0.0
                                          France
     198
         199
                           2.0
                                   Paris
                                          France
                                                    male 31.0
                                                                           0
                                                                                     1.0
                                                                                                 0
                                                                                                     02/12/20
                           3.0
                                   Paris
                                          France
                                                  female 30.0
                                                                                                     02/12/20
     199 200
                                                                           0
                                                                                     1.0
                                                                                                0
     200 201
                           4.0
                                   Paris
                                          France
                                                    male 80.0
                                                                           0
                                                                                     1.0
                                                                                         2/14/2020
                                                                                                           0
     209 210
                          13.0
                                   Paris
                                          France
                                                  female 33.0
                                                                                     0.0
                                                                                                           0
[ ] data_new_2.shape[0]
635
[ ] data_new_2['death'] = data_new_2['death'].apply(lambda x: 0 if x=='0' else 1)
```

[ ] data\_new\_2['recovered'] = data\_new\_2['recovered'].apply(lambda x: 0 if x=='0' else 1)



```
Codyveние модели

[ ] from sklearn.neighbors import KNeighborsClassifier

[ ] KNeighborsClassifierObj = KNeighborsClassifier(n_neighbors=10)

[ ] KNeighborsClassifierObj.fit(X_cov, y_cov)

② KNeighborsClassifier(algorithm='auto', leaf_size=30, metric='minkowski', metric_params=None, n_jobs=None, n_neighbors=10, p=2, weights='uniform')

[ ] y_predicted = KNeighborsClassifierObj.predict(X_test)

Метрика качества

[ ] from sklearn.metrics import accuracy_score, balanced_accuracy_score, precision_score, f1_score, classification_report

[ ] accuracy_score(y_test, y_predicted)

② 0.9606299212598425

[ ] precision_score(y_test, y_predicted)

③ 0.0
```

Смертность не зависит от других параметров.

## Кросс-валидация

```
[ ] from sklearn.model_selection import GridSearchCV
[ ] n_range = np.array(range(5,55,5))
    tuned_parameters = [{'n_neighbors': n_range}]
[ ] clf gs = GridSearchCV(KNeighborsClassifier(), tuned parameters, cv=5, scoring='f1 weighted')
[ ] clf_gs.fit(X_cov, y_cov)
GridSearchCV(cv=5, error score=nan,
                 estimator=KNeighborsClassifier(algorithm='auto', leaf_size=30,
                                               metric='minkowski',
                                               metric_params=None, n_jobs=None,
                                               n_neighbors=5, p=2,
                                               weights='uniform'),
                 iid='deprecated', n_jobs=None,
                 param_grid=[{'n_neighbors': array([ 5, 10, 15, 20, 25, 30, 35, 40, 45, 50])}],
                 pre_dispatch='2*n_jobs', refit=True, return_train_score=False,
                 scoring='f1 weighted', verbose=0)
[ ] clf_gs.best_params_
   {'n_neighbors': 5}
[ ] clf_gs.best_score_
0.9588742014124028
                plt.plot(n_range, clf_gs.cv_results_['mean_test_score'])
                [<matplotlib.lines.Line2D at 0x7f1752b97278>]
                 1.00
                 0.98
                 0.96
                 0.94
                 0.92
                                       20
                            10
                                                  30
                                                                        50
```

```
[] #Случайный лес
     from sklearn.ensemble import RandomForestClassifier, ExtraTreesClassifier
[ ] forest = RandomForestClassifier(n_estimators=50, oob_score=True, random_state=1)
     forest.fit(X_cov, y_cov)
   RandomForestClassifier(bootstrap=True, ccp alpha=0.0, class weight=None,
                           criterion='gini', max depth=None, max features='auto',
                           max leaf nodes=None, max samples=None,
                           min impurity decrease=0.0, min impurity split=None,
                           min samples leaf=1, min samples split=2,
                           min weight fraction leaf=0.0, n estimators=50,
                           n jobs=None, oob score=True, random state=1, verbose=0,
                           warm start=False)
[ ] forest.score(X test,y test)
    0.9448818897637795
[ ] y predicted forest = forest.predict(X test)
[ ] classification_report(y_predicted_forest,y_test, output_dict=True)
{'0': {'f1-score': 0.9714285714285714,
       'precision': 0.991666666666667,
       'recall': 0.952,
       'support': 125},
      '1': {'f1-score': 0.2222222222222224,
       'precision': 0.14285714285714285,
       'recall': 0.5,
       'support': 2},
      'accuracy': 0.9448818897637795,
      'macro avg': {'f1-score': 0.5968253968253968,
       'precision': 0.5672619047619047,
       'recall': 0.726,
       'support': 127},
      'weighted avg': {'f1-score': 0.9596300462442194,
       'precision': 0.9782995875515562,
       'recall': 0.9448818897637795,
```

'support': 127}}

```
[] #Градиентный бустинг
    from sklearn.ensemble import AdaBoostClassifier
    ab1 = AdaBoostClassifier(n_estimators=50, algorithm='SAMME', random_state=1)
    ab1.fit(X_cov, y_cov)
AdaBoostClassifier(algorithm='SAMME', base_estimator=None, learning_rate=1.0,
                       n_estimators=50, random_state=1)
ab1.score(X test,y test)
0.9448818897637795
[ ] y_predicted_ab = ab1.predict(X_test)
[ ] classification_report(y_predicted_ab,y_test, output_dict=True)
{'0': {'f1-score': 0.97165991902834.
       'precision': 1.0,
      recall': 0.9448818897637795,
      'support': 127},
     '1': {'f1-score': 0.0, 'precision': 0.0, 'recall': 0.0, 'support': 0},
     'accuracy': 0.9448818897637795,
     'macro avg': {'f1-score': 0.48582995951417,
      'precision': 0.5,
      'recall': 0.47244094488188976,
      'support': 127},
     'weighted avg': {'f1-score': 0.97165991902834,
      'precision': 1.0,
      'recall': 0.9448818897637795,
      'support': 127}}
```

Все модели дают одинаковые хорошие результаты по всем метрикам качества модели.